.UBAfiuba
FACULTAD DE INGENIERÍA

Clasificación automática de modulaciones de señales de radiofrecuencia mediante machine learning

Manuel Dieguez

Carrera de Especialización en Inteligencia Artificial

Director: Dr. Rodríguez Colmeiro, Ramiro Germán (UTN - UTT)

Codirector: Ing. De Cesare, Pablo Nicolás (UTN)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Ciudad Autónoma de Buenos Aires, noviembre de 2025

Resumen

Se implementaron y compararon múltiples arquitecturas para la clasificación automática de modulaciones en señales de radio, con el objetivo de identificar la que ofreciera la mejor relación entre exactitud y complejidad computacional. Se utilizó conjuntos de datos sintéticos, comprendiendo ocho esquemas de modulaciones digital evaluados en un rango de niveles de ruido de -20 dB a 18 dB. Los resultados mostraron que, a igual número de parámetros, las arquitecturas que utilizaban preprocesamientos mejoran su exactitud, y que a niveles de ruido muy bajos todos los modelos convergieron a un desempeño cercano al azar. La memoria presenta el diseño del pipeline de datos, las arquitecturas evaluadas, el proceso de entrenamiento y los resultados comparativos, e integra conocimientos de aprendizaje profundo, modelos clásicos y procesamiento de datos de la Carrera de Especialización en Inteligencia Artificial, y procesamiento de señales debido al transfondo del autor en la rama de telecomunicaciones.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen I

1. Introducción general 1
1.1. Reconocimiento automático de modulaciones . . . 1
1.2. Contexto y motivación . . . 2
1.3. Estado del arte . . . 2
1.4. Objetivos del trabajo . . . 3

2. Introducción específica 5
2.1. Estilo y convenciones . . . 5
2.1.1. Uso de mayúscula inicial para los título de secciones . . . 5
2.1.2. Este es el título de una subsección . . . 5
2.1.3. Figuras . . . 6
2.1.4. Tablas . . . 7
2.1.5. Ecuaciones . . . 8

3. Diseño e implementación 9
3.1. Análisis del software . . . 9

4. Ensayos y resultados 11
4.1. Pruebas funcionales del hardware . . . 11

5. Conclusiones 13
5.1. Conclusiones generales . . . 13
5.2. Próximos pasos . . . 13

Bibliografía 15

Índice de figuras

1.1. Diagrama de bloques del sistema de AMC. 1

2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo. 6
2.2. Imagen tomada de la página oficial del procesador[1]. 7
2.3. ¿Por qué de pronto aparece esta figura? 7
2.4. Tres gráficos simples. 7

Índice de tablas

2.1. caption corto 8

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presenta el contexto general del trabajo, se describe el problema del reconocimiento automático de modulaciones y su importancia en comunicaciones digitales, se analiza el estado del arte en el área y se enuncian los objetivos que guiaron el desarrollo del trabajo.

1.1. Reconocimiento automático de modulaciones

El reconocimiento automático de modulaciones (AMC, del inglés *Automatic Modulation Classification*) es un problema fundamental en comunicaciones digitales que consiste en identificar el esquema de modulación de una señal recibida sin información previa sobre el emisor ni el canal de transmisión. Entre sus aplicaciones se destacan el monitoreo del espectro radioeléctrico, la detección de emisores no autorizados, la radio cognitiva y las comunicaciones en entornos adversos [1].

Un sistema de AMC recibe como entrada muestras de una señal de radio digital en formato IQ, es decir, sus componentes en fase (I) y cuadratura (Q), y produce como salida la etiqueta del esquema de modulación identificado. El procesamiento se divide en cuatro etapas secuenciales: adquisición de la señal, preprocesamiento, clasificación mediante un modelo de aprendizaje automático y asignación de la etiqueta de modulación. Esta arquitectura de procesamiento permite configurar al receptor para demodular la señal según la modulación identificada.

En la figura 1.1 se puede observar un diagrama de bloques del sistema de AMC.



FIGURA 1.1. Diagrama de bloques del sistema de AMC.

La relación señal a ruido (SNR, del inglés *Signal-to-Noise Ratio*) es la variable que más condiciona el desempeño de los sistemas de AMC. A niveles de SNR elevados (por encima de 0 dB), las distintas modulaciones presentan características diferenciables que permiten una clasificación precisa. A niveles bajos de SNR (por debajo de -10 dB), la señal es prácticamente indistinguible del ruido y la tarea de clasificación se vuelve muy difícil para cualquier método conocido [2].

1.2. Contexto y motivación

Los métodos tradicionales de AMC se basan en el análisis manual de características de la señal, tales como la transformada de Fourier, la autocorrelación, estadísticas de la envolvente y momentos de orden superior. Estos métodos fueron diseñados para subconjuntos específicos de modulaciones y su desempeño se degrada significativamente en condiciones de baja SNR. Además, requieren un diseño ad hoc para cada nuevo esquema de modulación, lo que limita su escalabilidad [1].

El enfoque basado en aprendizaje profundo superó a los métodos clásicos y se convirtió en el paradigma dominante para AMC [3]. En particular, las redes neuronales convolucionales (CNN, del inglés *Convolutional Neural Network*) que operan directamente sobre las muestras IQ crudas de la señal lograron superar el desempeño de los métodos basados en características manuales [4]. Esta ventaja se hace especialmente evidente en condiciones de SNR moderado a alto.

Sin embargo, la búsqueda de mayor exactitud llevó al desarrollo de arquitecturas de creciente complejidad, con modelos cuya cantidad de parámetros hace inviable su implementación dentro de un procesador que pueda utilizarse en aplicaciones de radiofrecuencia en tiempo real. Esto genera una tensión fundamental: los modelos más precisos son computacionalmente inviables para su implementación en hardware de tiempo real, que es precisamente el entorno donde AMC tiene sus aplicaciones más directas.

La propuesta de valor de este trabajo reside en buscar la mejor relación entre complejidad del modelo y exactitud de clasificación. Se investigaron diferentes arquitecturas de aprendizaje profundo con el objetivo de identificar cuál ofrece el mejor equilibrio entre desempeño y cantidad de parámetros, de modo que el modelo resultante pueda ser llevado a sistemas con recursos computacionales limitados, como puede ser un sistema embebido o una radio definida por software (SDR, del inglés *Software Defined Radio*).

El presente trabajo es de carácter personal y académico y no involucra acuerdos de confidencialidad ni financiamiento externo.

1.3. Estado del arte

El estado del arte actual en AMC está dominado por métodos de aprendizaje profundo que operan directamente sobre las muestras IQ de la señal, sin extracción manual de características. Este enfoque supera sistemáticamente a los métodos clásicos basados en estadísticas de la señal, especialmente en condiciones de SNR moderado a alto.

Entre las arquitecturas de redes neuronales más utilizadas para AMC se encuentran las redes convolucionales (CNN), las redes recurrentes tipo LSTM (del inglés *Long Short-Term Memory*) y GRU (del inglés *Gated Recurrent Unit*), y las redes convolucionales temporales (TCN, del inglés *Temporal Convolutional Network*). Cada arquitectura explota diferentes propiedades de la señal: las CNN capturan patrones locales en las muestras IQ, las redes recurrentes modelan dependencias temporales a largo plazo, y las TCN combinan la capacidad de procesamiento paralelo de las CNN con un campo receptivo extendido mediante convoluciones dilatadas [4, 5, 6].

Los modelos actuales logran una exactitud promedio superior al 80 % en condiciones de SNR de 0 dB en adelante cuando se evalúan sobre el dataset RadioML 2016.10a, que es el conjunto de datos de referencia más utilizado en la literatura [4, 2]. Sin embargo, el desempeño cae drásticamente por debajo de ese umbral de SNR, lo que indica que el problema de clasificación a bajo SNR permanece abierto [2].

1.4. Objetivos del trabajo

El objetivo general del trabajo consiste en desarrollar un sistema de clasificación automática de modulaciones de señales de radio que ofrezca la mejor relación entre exactitud de clasificación y complejidad algorítmica, con el fin de identificar modelos viables para su implementación en sistemas con recursos computacionales limitados.

Para alcanzar este objetivo se definieron los siguientes objetivos específicos:

- Analizar el dataset RadioML 2016.10a mediante la visualización de señales en el plano IQ por clase de modulación, el análisis espectral de las distintas modulaciones y el estudio de la separabilidad de clases en función del nivel de SNR.
- Preprocesar las muestras IQ mediante normalización y dividir el dataset en conjuntos de entrenamiento, validación y prueba, manteniendo la distribución de clases y niveles de SNR.
- Investigar, diseñar e implementar arquitecturas de redes neuronales aplicables al problema de AMC, incluyendo CNN, LSTM, GRU y TCN, evaluadas tanto sobre las representaciones IQ crudas como sobre la representación en amplitud y fase.
- Entrenar los modelos y ajustar sus hiperparámetros, analizando el impacto del aumento de datos y del uso de scheduler de tasa de aprendizaje.
- Evaluar el desempeño de los modelos mediante métricas de exactitud global, exactitud en función del nivel de SNR, matriz de confusión y cantidad de parámetros del modelo.
- Comparar las arquitecturas evaluadas considerando el compromiso entre exactitud y complejidad algorítmica.
- Analizar las limitaciones del sistema desarrollado, incluyendo su comportamiento a bajo SNR y las restricciones derivadas del carácter sintético del dataset.

El alcance del trabajo no incluye la implementación del modelo en hardware de tiempo real (FPGA, microcontrolador u otros dispositivos embebidos), la prueba con señales reales capturadas mediante un receptor SDR, la medición de tiempos de inferencia en hardware específico ni el despliegue del modelo en un entorno de producción. El análisis de complejidad se limita a la comparación del número de parámetros de cada arquitectura.

Capítulo 2

Introducción específica

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

2.1. Estilo y convenciones

2.1.1. Uso de mayúscula inicial para los título de secciones

Si en el texto se hace alusión a diferentes partes del trabajo referirse a ellas como capítulo, sección o subsección según corresponda. Por ejemplo: "En el capítulo 1 se explica tal cosa", o "En la sección 2.1 se presenta lo que sea", o "En la subsección 2.1.2 se discute otra cosa".

Cuando se quiere poner una lista tabulada, se hace así:

- Este es el primer elemento de la lista.
- Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

Si se desea poner una lista numerada el formato es este:

1. Este es el primer elemento de la lista.
2. Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

2.1.2. Este es el título de una subsección

Se recomienda no utilizar **texto en negritas** en ningún párrafo, ni tampoco texto subrayado. En cambio sí se debe utilizar *texto en itálicas* para palabras en un idioma extranjero, al menos la primera vez que aparecen en el texto. En el caso de palabras que estamos inventando se deben utilizar "comillas", así como también para citas textuales. Por ejemplo, un *digital filter* es una especie de "selector" que permite separar ciertos componentes armónicos en particular.

La escritura debe ser impersonal. Por ejemplo, no utilizar "el diseño del firmware lo hice de acuerdo con tal principio", sino "el firmware fue diseñado utilizando tal principio".

El trabajo es algo que al momento de escribir la memoria se supone que ya está concluido, entonces todo lo que se refiera a hacer el trabajo se narra en tiempo pasado, porque es algo que ya ocurrió. Por ejemplo, "se diseñó el firmware empleando la técnica de test driven development".

En cambio, la memoria es algo que está vivo cada vez que el lector la lee. Por eso transcurre siempre en tiempo presente, como por ejemplo:

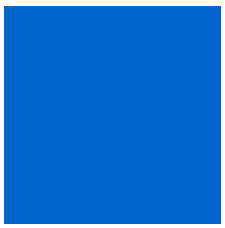
“En el presente capítulo se da una visión global sobre las distintas pruebas realizadas y los resultados obtenidos. Se explica el modo en que fueron llevados a cabo los test unitarios y las pruebas del sistema”.

Se recomienda no utilizar una sección de glosario sino colocar la descripción de las abreviaturas como parte del mismo cuerpo del texto. Por ejemplo, RTOS (*Real Time Operating System*, Sistema Operativo de Tiempo Real) o en caso de considerarlo apropiado mediante notas a pie de página.

Si se desea indicar alguna página web utilizar el siguiente formato de referencias bibliográficas, dónde las referencias se detallan en la sección de bibliografía de la memoria, utilizado el formato establecido por IEEE en [7]. Por ejemplo, “el presente trabajo se basa en la plataforma EDU-CIAA-NXP [8], la cual...”.

2.1.3. Figuras

Al insertar figuras en la memoria se deben considerar determinadas pautas. Para empezar, usar siempre tipografía claramente legible. Luego, tener claro que **es incorrecto** escribir por ejemplo esto: “El diseño elegido es un cuadrado, como se ve en la siguiente figura:”



La forma correcta de utilizar una figura es con referencias cruzadas, por ejemplo: “Se eligió utilizar un cuadrado azul para el logo, como puede observarse en la figura 2.1”.

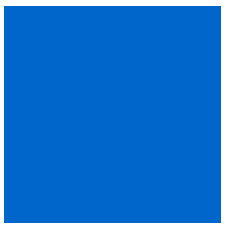


FIGURA 2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo.

El texto de las figuras debe estar siempre en español, excepto que se decida reproducir una figura original tomada de alguna referencia. En ese caso la referencia de la cual se tomó la figura debe ser indicada en el epígrafe de la figura e incluida como una nota al pie, como se ilustra en la figura 2.2.



FIGURA 2.2. Imagen tomada de la página oficial del procesador[1].

La figura y el epígrafe deben conformar una unidad cuyo significado principal pueda ser comprendido por el lector sin necesidad de leer el cuerpo central de la memoria. Para eso es necesario que el epígrafe sea todo lo detallado que corresponda y si en la figura se utilizan abreviaturas entonces aclarar su significado en el epígrafe o en la misma figura.



FIGURA 2.3. ¿Por qué de pronto aparece esta figura?

Nunca colocar una figura en el documento antes de hacer la primera referencia a ella, como se ilustra con la figura 2.3, porque sino el lector no comprenderá por qué de pronto aparece la figura en el documento, lo que distraerá su atención.

Otra posibilidad es utilizar el entorno *subfigure* para incluir más de una figura, como se puede ver en la figura 2.4. Notar que se pueden referenciar también las figuras internas individualmente de esta manera: 2.4a, 2.4b y 2.4c.



(A) Un caption.



(B) Otro.



(C) Y otro más.

FIGURA 2.4. Tres gráficos simples.

El código para generar las imágenes se encuentra disponible para su reutilización en el archivo Chapter2.tex.

2.1.4. Tablas

Para las tablas utilizar el mismo formato que para las figuras, sólo que el epígrafe se debe colocar arriba de la tabla, como se ilustra en la tabla 2.1. Observar que sólo algunas filas van con líneas visibles y notar el uso de las negritas para los encabezados. La referencia se logra utilizando el comando `\ref{<label>}` donde label debe estar definida dentro del entorno de la tabla.

[1]Imagen tomada de https://goo.gl/images/i7C70w

```
\begin{table}[h]
 \centering
 \caption[caption corto]{caption largo más descriptivo}
 \begin{tabular}{l c c}
  \toprule
  \textbf{Especie}     & \textbf{Tamaño} & \textbf{Valor}\\
  \midrule
  Amphiprion Ocellaris & 10 cm           & \$ 6.000 \\
  Hepatus Blue Tang    & 15 cm           & \$ 7.000 \\
  Zebrasoma Xanthurus  & 12 cm           & \$ 6.800 \\
  \bottomrule
  \hline
 \end{tabular}
 \label{tab:peces}
\end{table}
```

TABLA 2.1. caption largo más descriptivo.

Especie	**Tamaño**	**Valor**
Amphiprion Ocellaris	10 cm	$ 6.000
Hepatus Blue Tang	15 cm	$ 7.000
Zebrasoma Xanthurus	12 cm	$ 6.800

En cada capítulo se debe reiniciar el número de conteo de las figuras y las tablas, por ejemplo, figura 2.1 o tabla 2.1, pero no se debe reiniciar el conteo en cada sección. Por suerte la plantilla se encarga de esto por nosotros.

2.1.5. Ecuaciones

Al insertar ecuaciones en la memoria dentro de un entorno *equation*, éstas se numeran en forma automática y se pueden referir al igual que como se hace con las figuras y tablas, por ejemplo ver la ecuación 2.1.

$$ds^2 = c^2 dt^2 \left(\frac{d\sigma^2}{1 - k\sigma^2} + \sigma^2 \left[d\theta^2 + \sin^2 \theta d\phi^2 \right] \right) \tag{2.1}$$

Para generar la ecuación 2.1 se utilizó el siguiente código:

```
\begin{equation}
 \label{eq:metric}
 ds^2 = c^2 dt^2 \left( \frac{d\sigma^2}{1-k\sigma^2} +
 \sigma^2\left[ d\theta^2 +
 \sin^2\theta d\phi^2 \right] \right)
\end{equation}
```

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno lstlisting con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
 las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código 3.1:

```
#define MAX_SENSOR_NUMBER 3
#define MAX_ALARM_NUMBER  6
#define MAX_ACTUATOR_NUMBER 6

uint32_t sensorValue[MAX_SENSOR_NUMBER];
FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
state_t alarmState[MAX_ALARM_NUMBER];           //ON or OFF
state_t actuatorState[MAX_ACTUATOR_NUMBER];     //ON or OFF

void vControl() {

  initGlobalVariables();

  period = 500 ms;

  while(1) {

    ticks = xTaskGetTickCount();

    updateSensors();

    updateAlarms();

    controlActuators();

    vTaskDelayUntil(&ticks, period);
  }
```

```
28 }
```

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se puedo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

[1] O. A. Dobre et al. «Survey of automatic modulation classification techniques: classical approaches and new trends». En: *IET Communications* 1.2 (2007), págs. 137-156. DOI: 10.1049/iet-com:20050176.

[2] T. J. O'Shea, T. Roy y T. C. Clancy. «Over-the-air deep learning based radio signal classification». En: *IEEE Journal of Selected Topics in Signal Processing* 12.1 (2018), págs. 168-179. DOI: 10.1109/JSTSP.2018.2797022.

[3] T. J. O'Shea y J. Hoydis. «An introduction to deep learning for the physical layer». En: *IEEE Transactions on Cognitive Communications and Networking* 3.4 (2017), págs. 563-575. DOI: 10.1109/TCCN.2017.2758370.

[4] T. J. O'Shea, J. Corgan y T. C. Clancy. «Convolutional radio modulation recognition networks». En: *Proc. Engineering Applications of Neural Networks (EANN)*. arXiv:1602.04105. 2016.

[5] S. Peng et al. «Modulation classification based on signal constellation diagrams and deep learning». En: *IEEE Transactions on Neural Networks and Learning Systems* 30.3 (2019), págs. 718-727. DOI: 10.1109/TNNLS.2018.2850703.

[6] B. Kim et al. «Automatic modulation classification using recurrent neural networks». En: *IEEE Communications Letters* (2018). DOI: 10.1109/LCOMM.2018.2792026.

[7] IEEE. *IEEE Citation Reference*. 1.ª ed. IEEE Publications, 2016. URL: http://www.ieee.org/documents/ieeecitationref.pdf (visitado 26-09-2016).

[8] Proyecto CIAA. *Computadora Industrial Abierta Argentina*. Visitado el 2016-06-25. 2014. URL: http://proyecto-ciaa.com.ar/devwiki/doku.php?id=start.